T2: Funções Geradoras, Molloy–Reed e a Matriz de Hashimoto

No handout T1 resolvemos a percolação em árvores regulares. Aqui generalizamos para redes com *qualquer* distribuição de graus, usando funções geradoras. Depois reescrevemos o mesmo resultado na linguagem de matrizes: a matriz de adjacência A e a matriz não-retroativa B de Hashimoto. O fio condutor é uma pergunta só: *quantos caminhos novos se abrem a cada passo?* No fim, testamos tudo na malha real de Fortaleza e vemos onde essas teorias falham.

Para ler mais: M. E. J. Newman, *Networks* (2ª ed., Oxford, 2018), caps. 12 e 15; R. Cohen *et al.*, Phys. Rev. Lett. **85**, 4626 (2000); B. Karrer, M. E. J. Newman e L. Zdeborová, Phys. Rev. Lett. **113**, 208702 (2014). Pré-requisitos: séries de potências, autovalores e o handout T1. *Total: 25 pontos.*

1 Funções geradoras de graus

Seja p_k a fração de nós com grau k. Toda a informação está na *função geradora*

$$G_0(x) = \sum_{k\geq 0} p_k x^k, \qquad G_0(1) = 1, \quad G_0'(1) = \langle k\rangle\,, \quad G_0''(1) = \left\langle k^2\right\rangle - \langle k\rangle\,.$$

Agora a pergunta que importa para percolação: se eu *chego* a um nó andando por uma aresta, qual é o grau dele? Não é p_k! Um nó de grau k tem k arestas chegando nele, então é k vezes mais provável chegar nele. A probabilidade é $kp_k/\langle k\rangle$. Quem chega já usou uma aresta, então sobram $k-1$ arestas "novas", o *grau excedente*.

Ideia 1

O grau excedente de um nó alcançado por uma aresta tem distribuição $q_k = (k+1)p_{k+1}/\langle k\rangle$, com função geradora

$$G_1(x) = \sum_k q_k x^k = \frac{G_0'(x)}{G_0'(1)}.$$

A média, $G_1'(1) = \dfrac{\left\langle k^2\right\rangle - \langle k\rangle}{\langle k\rangle}$, é o **fator de ramificação**: quantos caminhos novos se abrem, em média, a cada passo.

Exemplo 1. Calcule G_0 e G_1 para (a) a rede regular de grau z e (b) a rede de Erdős–Rényi, cuja distribuição de graus é Poisson com média c.

Solução. (a) $G_0 = x^z$ e $G_1 = zx^{z-1}/z = x^{z-1}$, com fator de ramificação $z-1$, como na árvore de Bethe. (b) $G_0 = \sum_k e^{-c}c^k x^k/k! = e^{c(x-1)}$, e $G_1 = c\,e^{c(x-1)}/c = G_0$. Para Poisson, o grau excedente tem a mesma distribuição que o grau: o fator de ramificação é c. ◂

[2] Problema 1. O paradoxo da amizade. Mostre que o grau médio de um vizinho, $\langle k\rangle_{\text{viz}} = \left\langle k^2\right\rangle/\langle k\rangle$, é sempre $\geq \langle k\rangle$, com igualdade só se todos os nós tiverem o mesmo grau. Interprete para uma malha viária: por que um cruzamento "visitado" por um carro tende a ser maior que um cruzamento típico?

2 O componente gigante e o critério de Molloy–Reed

Seja u a probabilidade de que uma aresta *não* leve ao componente gigante, ou seja, de que tudo o que se alcança por ela seja finito. Num grafo sem laços curtos ("localmente árvore"), isso acontece se *todas* as arestas excedentes do nó do outro lado também não levarem ao gigante:

$$u = \sum_k q_k u^k = G_1(u), \qquad S = 1 - G_0(u),$$

onde S é a fração de nós no gigante.

Exemplo 2. Mostre que existe componente gigante se, e só se, $\kappa \equiv \langle k^2 \rangle / \langle k \rangle > 2$ (critério de Molloy–Reed).

Solução. $u = 1$ sempre é solução ($G_1(1) = 1$) e dá $S = 0$. Queremos outra solução em $[0, 1)$. G_1 tem coeficientes não-negativos, então é crescente e convexa em $[0, 1]$, com $G_1(0) = q_0 \geq 0$. Desenhe $y = G_1(u)$ e $y = u$. Se a inclinação em $u = 1$ for $G_1'(1) \leq 1$, a curva convexa fica acima da reta em todo $[0, 1)$, e só $u = 1$ é solução. Se $G_1'(1) > 1$, a curva cruza a reta por baixo perto de $u = 1$, e como $G_1(0) \geq 0$ ela precisa cruzar de novo em algum $u^* < 1$. Logo existe gigante se, e só se,

$$G_1'(1) = \frac{\langle k^2 \rangle - \langle k \rangle}{\langle k \rangle} > 1 \iff \langle k^2 \rangle - 2\langle k \rangle > 0 \iff \kappa > 2.$$

◀

Agora acrescente a percolação: cada aresta está aberta com probabilidade p. Uma aresta não leva ao gigante se estiver fechada ou se estiver aberta e o resto for finito:

$$u = 1 - p + p\, G_1(u), \qquad S = 1 - G_0(1 - p + pu).$$

Ideia 2

Repetindo o argumento gráfico, o gigante existe se $p\, G_1'(1) > 1$:

$$p_c = \frac{1}{G_1'(1)} = \frac{\langle k \rangle}{\langle k^2 \rangle - \langle k \rangle} = \frac{1}{\kappa - 1}.$$

Para redes livres de escala com $p_k \sim k^{-\gamma}$ e $\gamma < 3$, $\langle k^2 \rangle$ diverge e $p_c \to 0$: a rede não se quebra com falhas aleatórias (Cohen *et al.*, 2000). Malhas viárias são o extremo oposto: o grau é limitado (quase todo cruzamento tem grau 3 ou 4) e a rede é *plana*.

[3] Problema 2. Para Erdős–Rényi com grau médio c e percolação de ligações com probabilidade p:

(a) Mostre que $S = 1 - e^{-cpS}$ e que $p_c = 1/c$.

(b) Expanda para $cp = 1 + \varepsilon$ e mostre que $S \approx 2\varepsilon$. Qual é o expoente β? Compare com a árvore de Bethe do T1.

[3] Problema 3. Ruas em série. Uma rua com um nó intermediário de grau 2 (por exemplo, uma curva) é formada por duas ligações em série.

(a) Mostre que, para a percolação, um caminho de m ligações em série, sem ramificações, equivale a uma única ligação aberta com probabilidade p^m.

(b) O `osmnx` "simplifica" a malha removendo nós de grau 2 e juntando os trechos. No protocolo de trânsito, se os trechos têm velocidades relativas $r_1, \dots, r_m$, qual r deve ter a via juntada para que a percolação não mude? (Resposta curta.)

(c) Na distribuição de graus da malha de Fortaleza (tabela abaixo) quase não há nós de grau 2. Por quê?

k	1	2	3	4	5	6	7
p_k (Fortaleza)	0,068	0,053	0,396	0,430	0,032	0,016	0,004

[2] Problema 4. Com a tabela acima, a malha de Fortaleza tem $\langle k \rangle = 3{,}373$ e $\langle k^2 \rangle = 12{,}355$. Calcule κ e o p_c previsto pela fórmula de Molloy–Reed. Compare com o valor medido por simulação na própria malha, $p_c = 0{,}564 \pm 0{,}002$. Por que o erro é tão grande? (Volte a este problema depois da Seção 4.)

3 O espectro da matriz de adjacência

A matriz de adjacência A tem $A_{ij} = 1$ se i e j são vizinhos. O elemento $(A^n)_{ij}$ conta os passeios de n passos de i até j. Para um grafo conexo, o teorema de Perron–Frobenius garante que o maior autovalor $\lambda_1(A)$ é real e simples e tem autovetor com todas as entradas positivas (a *centralidade de autovetor*). O número de passeios longos cresce como λ_1^n.

> **Ideia 3**
> Linearizando a percolação em torno de "ninguém conectado" e contando passeios, obtemos a estimativa $p_c \approx 1/\lambda_1(A)$. Ela é sistematicamente *baixa demais*, porque passeios podem voltar pela aresta de onde vieram: $i \to j \to i$ não abre caminho novo nenhum, mas é contado como se abrisse.

[3] Problema 5. Cotas inferiores para $\lambda_1(A)$. Use o quociente de Rayleigh, $\lambda_1 = \max_{\boldsymbol{x} \neq 0} \boldsymbol{x}^{\top} A \boldsymbol{x} / \boldsymbol{x}^{\top} \boldsymbol{x}$, para uma matriz simétrica.

(a) Com $\boldsymbol{x} = \mathbf{1}$, mostre que $\lambda_1 \geq \langle k \rangle$.

(b) Usando $\lambda_1(A)^2 = \lambda_1(A^2)$ e $\boldsymbol{x} = \mathbf{1}$, mostre que $\lambda_1 \geq \sqrt{\langle k^2 \rangle}$.

(c) Mostre que uma estrela com k pontas tem $\lambda_1 = \sqrt{k}$. Conclua que $\lambda_1 \geq \sqrt{k_{\max}}$ em qualquer grafo. (Use que o λ_1 de um subgrafo é no máximo o do grafo.)

(d) Para Fortaleza, $\lambda_1(A) = 4{,}08$. Calcule $1/\lambda_1(A)$ e compare com o p_c medido.

4 A matriz não-retroativa de Hashimoto

Para eliminar os passeios que voltam pela mesma aresta, trocamos de espaço: em vez de nós, usamos as $2E$ *arestas orientadas* $u \to v$.

> **Ideia 4**
> A **matriz de Hashimoto** B é a matriz $2E \times 2E$
>
> $$B_{(u \to v),(w \to x)} = \begin{cases} 1 & \text{se } v = w \text{ e } x \neq u, \\ 0 & \text{caso contrário.} \end{cases}$$

Ela "continua" a aresta $u \to v$ para qualquer aresta saindo de v, *exceto* a volta $v \to u$. Então (B^n) conta passeios *não-retroativos*. A linha da aresta $u \to v$ tem $k_v - 1$ uns: exatamente o grau excedente.

Percolação por troca de mensagens. Seja $u_{j\to i}$ a probabilidade de que o nó i *não* se conecte ao gigante através do vizinho j. Isso acontece se a ligação ij estiver fechada, ou se estiver aberta e j não se conectar ao gigante por nenhum outro vizinho:

$$u_{j\to i} = 1 - p + p \prod_{k\in\partial j\setminus i} u_{k\to j}.$$

Escrevendo $u = 1 - \delta$ e linearizando para δ pequeno,

$$\delta_{j\to i} = p \sum_{k\in\partial j\setminus i} \delta_{k\to j} = p\,(B^{\top}\boldsymbol{\delta})_{j\to i}.$$

A solução $\boldsymbol{\delta} = 0$ (sem gigante) fica instável quando $p\,\lambda_1(B) > 1$:

$$p_c^{\mathrm{MP}} = \frac{1}{\lambda_1(B)}.$$

Isso é *exato* em árvores e é a melhor estimativa "localmente árvore" em redes esparsas (Karrer, Newman & Zdeborová, 2014).

Exemplo 3. Calcule $\lambda_1(B)$ e $\lambda_1(A)$ para um anel com N nós e compare as duas estimativas de p_c com o valor exato.

Solução. No anel, toda aresta orientada tem exatamente uma continuação não-retroativa: quem anda no sentido horário continua no sentido horário. Então B é uma matriz de permutação (dois ciclos de comprimento N, um para cada sentido), e todos os seus autovalores têm módulo 1, logo $\lambda_1(B) = 1$ e $p_c^{\mathrm{MP}} = 1$. Esse é exatamente o resultado da cadeia 1D do T1: basta um corte para separar. Já A tem $\lambda_1(A) = 2$ (todo nó tem grau 2, autovetor $\mathbf{1}$), e a estimativa $1/\lambda_1(A) = 1/2$ está errada por um fator 2. A diferença é inteira devida aos passeios que voltam. ◂

[2] Problema 6. Rede regular. Mostre que, num grafo em que todo nó tem grau z, o vetor $\mathbf{1}$ (de dimensão $2E$) é autovetor de B com autovalor $z - 1$, e conclua que $p_c^{\mathrm{MP}} = 1/(z-1)$, o resultado de Bethe.

[4] Problema 7. Ihara–Bass: de $2E$ para $2N$. A matriz B é enorme, mas seus autovalores (fora ± 1) coincidem com os da matriz $2N \times 2N$

$$M = \begin{pmatrix} A & I - D \\ I & 0 \end{pmatrix},$$

onde D é a matriz diagonal dos graus.

(a) Suponha $M\binom{x}{y} = \lambda\binom{x}{y}$. Mostre que $\boldsymbol{x} = \lambda\boldsymbol{y}$ e que $\left(\lambda^2 I - \lambda A + D - I\right)\boldsymbol{x} = 0$.

(b) Num grafo z-regular, $\boldsymbol{x} = \mathbf{1}$ é autovetor de A com autovalor z. Resolva a equação quadrática em λ e confira que aparece $\lambda = z - 1$.

(c) Por que essa forma é útil no computador? Compare o tamanho de M e de B para Fortaleza ($N = 2470$, $E = 4166$).

[3] Problema 8. Configuração aleatória recupera Molloy–Reed. Num grafo aleatório com distribuição de graus p_k e sem correlação entre graus vizinhos, argumente que o vetor v com $v_{u\to v} = k_v - 1$ é aproximadamente autovetor de B e que $\lambda_1(B) \approx \langle k(k-1)\rangle / \langle k\rangle = \kappa - 1$. Conclua que p_c^{MP} coincide com a fórmula de Molloy–Reed.

[3] Problema 9. Onde a teoria quebra. Na rede quadrada, $\lambda_1(B) \to 3$ quando $L \to \infty$ (o cálculo numérico para $L = 60$ dá 2,992). Em Fortaleza, $\lambda_1(B) = 2{,}875$.

(a) Calcule p_c^{MP} para os dois casos e compare com os valores exatos/medidos: $1/2$ na rede quadrada e 0,564 em Fortaleza.

(b) A troca de mensagens supõe que as mensagens que chegam a um nó são independentes. Explique por que um quarteirão (um laço de comprimento 4) viola essa hipótese, e por que o erro é sempre no sentido de *subestimar* p_c.

(c) Monte a tabela das quatro estimativas de p_c para Fortaleza ($1/\lambda_1(A)$, Molloy–Reed, Hashimoto, simulação) e ordene-as. Qual a lição para quem quer usar teoria de redes aleatórias em cidades?

Observação. Em redes muito heterogêneas, o autovetor de $\lambda_1(A)$ fica "localizado" em poucos hubs e perde o sentido como centralidade. A versão com B (a *centralidade não-retroativa*) não sofre desse problema: T. Martin, X. Zhang e M. E. J. Newman, Phys. Rev. E **90**, 052808 (2014). Em malhas viárias, onde o grau é limitado, a localização é bem mais fraca.

Soluções

Problema 1. $\langle k\rangle_{\text{viz}} = \sum_k k \cdot kp_k/\langle k\rangle = \langle k^2\rangle/\langle k\rangle$, e $\langle k^2\rangle \geq \langle k\rangle^2$ (variância ≥ 0), com igualdade só se a variância for zero. Um carro chega a um cruzamento por uma rua, e cruzamentos com mais ruas recebem mais carros, simplesmente porque têm mais portas de entrada. Por isso as rotatórias e os grandes cruzamentos parecem "sempre cheios".

Problema 2. (a) O conjunto das arestas abertas forma outro grafo de Erdős–Rényi, com grau médio cp. Basta usar as fórmulas sem percolação com $c \to cp$: como $G_0 = G_1 = e^{cp(x-1)}$, temos $u = e^{cp(u-1)}$ e $S = 1 - G_0(u) = 1 - u$. Logo $S = 1 - e^{-cpS}$. A curva $1 - e^{-cpS}$ é côncava e tem inclinação cp em $S = 0$, então existe solução $S > 0$ se, e só se, $cp > 1$: $p_c = 1/c$. (b) Com $e^{-x} \approx 1 - x + x^2/2$: $S \approx cpS - (cpS)^2/2$. Dividindo por S, $S \approx 2(cp-1)/(cp)^2 \approx 2\varepsilon$. Logo $\beta = 1$, igual à árvore de Bethe: as duas são teorias de campo médio.

Problema 3. (a) O caminho conecta as pontas se, e só se, as m ligações estiverem abertas: probabilidade p^m. (b) A via juntada está aberta no nível q se e só se todos os trechos tiverem $r_i \geq q$, ou seja, se $\min_i r_i \geq q$. Então $r = \min_i r_i$: a rua é tão boa quanto seu pior trecho. No projeto, as velocidades são geradas direto para a via já simplificada, então isso é automaticamente consistente. Com dados reais de GPS por trecho, teríamos de usar o mínimo. (c) Porque o `osmnx` remove os nós de grau 2 na simplificação. Os que sobram ficam em pontos especiais, como o início de uma via de mão única ou o lugar onde a classe da via muda.

Problema 4. $\kappa = 12{,}355/3{,}373 = 3{,}663$ e $p_c^{\text{MR}} = 1/(\kappa - 1) = 0{,}376$, muito abaixo de 0,564 (erro de 33%). O motivo são os laços curtos dos quarteirões: veja a solução do Problema 9.

Problema 5. (a) $\mathbf{1}^\top A\mathbf{1} = \sum_{ij} A_{ij} = \sum_i k_i = N\langle k\rangle$ e $\mathbf{1}^\top\mathbf{1} = N$. (b) $\mathbf{1}^\top A^2\mathbf{1} = \|A\mathbf{1}\|^2 = \sum_i k_i^2 = N\langle k^2\rangle$, então $\lambda_1^2 \geq \langle k^2\rangle$. (c) Na estrela, tome $x_{\text{centro}} = \sqrt{k}$ e $x_{\text{ponta}} = 1$: $(A\boldsymbol{x})_{\text{centro}} = k = \sqrt{k}\cdot\sqrt{k}$ e $(A\boldsymbol{x})_{\text{ponta}} = \sqrt{k} = \sqrt{k}\cdot 1$. Como o nó de grau máximo e seus vizinhos contêm uma estrela, $\lambda_1 \geq \sqrt{k_{\max}}$. (d) $1/4{,}08 = 0{,}245$, menos da metade do valor medido. Note que $\lambda_1(A) = 4{,}08 > \sqrt{\langle k^2\rangle} = 3{,}52$: o autovetor se concentra na parte mais densa da malha.

Problema 6. $(B\mathbf{1})_{u\to v} = \#\{x \in \partial v : x \neq u\} = z - 1$ para toda aresta orientada. Como B é não-negativa e $\mathbf{1}$ é positivo, pelo teorema de Perron–Frobenius esse é o maior autovalor: $\lambda_1(B) = z - 1$ e $p_c^{\text{MP}} = 1/(z-1)$.

Problema 7. (a) A segunda linha dá $\boldsymbol{x} = \lambda\boldsymbol{y}$. A primeira dá $A\boldsymbol{x} + (I - D)\boldsymbol{y} = \lambda\boldsymbol{x}$. Substituindo $\boldsymbol{y} = \boldsymbol{x}/\lambda$ e multiplicando por λ: $\lambda A\boldsymbol{x} + (I - D)\boldsymbol{x} = \lambda^2\boldsymbol{x}$, ou seja, $(\lambda^2 I - \lambda A + D - I)\boldsymbol{x} = 0$. (b) Com $A\mathbf{1} = z\mathbf{1}$ e $D = zI$: $\lambda^2 - z\lambda + z - 1 = 0$, e $(\lambda - 1)(\lambda - (z-1)) = 0$. As raízes são $\lambda = 1$ e $\lambda = z - 1$. (c) M é 4940×4940 e B é 8332×8332. Mais importante, M tem só $2E + 2N \approx 13\,300$ entradas não nulas, enquanto B tem $\sum_v k_v(k_v - 1) \approx 22\,000$. Com `scipy.sparse.linalg.eigs`, M é a escolha natural.

Problema 8. Sem correlações, o nó v no fim de uma aresta tem grau excedente distribuído como q_k, independente de u. Então $(B\boldsymbol{v})_{u\to v} = \sum_{x\in\partial v\setminus u}(k_x - 1)$. Essa é uma soma de $k_v - 1$ termos, cada um com média $\langle k-1\rangle_{\text{aresta}} = \sum_k (k-1)kp_k/\langle k\rangle = \kappa - 1$. Logo $(B\boldsymbol{v})_{u\to v} \approx (\kappa - 1)(k_v - 1) = (\kappa - 1)v_{u\to v}$. Portanto $\lambda_1(B) \approx \kappa - 1$ e $p_c^{\text{MP}} = 1/(\kappa - 1)$, que é Molloy–Reed.

Problema 9. (a) Rede quadrada: $p_c^{\text{MP}} = 1/3$ contra $1/2$. Fortaleza: $1/2{,}875 = 0{,}348$ contra 0,564. (b) Num quarteirão, as mensagens que chegam a um cruzamento por dois lados diferentes do mesmo quarteirão dependem das *mesmas* ligações (as do outro lado do quarteirão), então são positivamente correlacionadas. A teoria trata como independentes "rotas" que, na verdade, compartilham ligações, e conta caminhos redundantes como se fossem novos. Isso superestima

a conectividade e, portanto, subestima p_c. (c) $1/\lambda_1(A) = 0{,}245$ < Hashimoto 0,348 < Molloy–Reed 0,376 < simulação 0,564. Cada refinamento melhora a estimativa, mas todas as teorias "localmente árvore" falham para malhas planas com laços curtos. Em cidades, **a simulação direta é obrigatória**, e é exatamente o que o pipeline faz. Há um detalhe: Hashimoto ficou um pouco abaixo de Molloy–Reed provavelmente por causa das correlações de grau da malha real e dos efeitos de borda, que o Problema 8 ignora.