T4: Escala de Tamanho Finito e Análise de Dados

Uma cidade não é infinita. O corredor Benfica–Centro–Aldeota tem $N \approx 2500$ cruzamentos, ou seja, um "tamanho linear" $L \sim \sqrt{N} \approx 50$ quarteirões. Os expoentes da tabela do T1 valem só no limite $L \to \infty$. Este handout ensina a extrair esses expoentes de sistemas finitos, que é a técnica central de qualquer trabalho numérico em fenômenos críticos. Ele também ensina a pôr barras de erro honestas nos resultados.

Todos os números da Seção 3 foram gerados com a função `limiar_critico` do projeto, em redes quadradas de $L = 16$ a 128.

Para ler mais: Stauffer & Aharony, cap. 4; M. E. J. Newman e G. T. Barkema, *Monte Carlo Methods in Statistical Physics* (Oxford, 1999), cap. 8; B. Efron e R. Tibshirani, *An Introduction to the Bootstrap* (1993). Pré-requisitos: T1. *Total: 17 pontos.*

1 A hipótese de escala

Perto de p_c, o único comprimento que importa num sistema infinito é $\xi \sim |p - p_c|^{-\nu}$. Num sistema finito, aparece um segundo comprimento, L. A hipótese de escala de tamanho finito diz que *tudo depende só da razão* L/ξ.

Ideia 1

Se uma grandeza diverge (ou vai a zero) como $X \sim |p - p_c|^{-x}$ no sistema infinito, num sistema de tamanho L ela vale

$$X(p, L) = L^{x/\nu}\, \mathcal{F}_X\left[(p - p_c)\, L^{1/\nu}\right].$$

A função $\mathcal{F}_X$ é universal e não depende de L. Duas consequências práticas:

- exatamente em p_c, $X(p_c, L) \sim L^{x/\nu}$, uma lei de potência em L;
- graficando $X\, L^{-x/\nu}$ contra $(p - p_c)L^{1/\nu}$, as curvas de todos os L caem *umas sobre as outras* (o *colapso de dados*).

Por exemplo, $S_1/N \sim |p - p_c|^{\beta}$ dá $S_1/N = L^{-\beta/\nu}\mathcal{F}[(p - p_c)L^{1/\nu}]$, e o maior cluster em p_c tem massa $S_1 \sim L^{d-\beta/\nu} = L^{d_f}$.

Exemplo 1. Cada amostra (cada "dia") de tamanho L tem seu próprio limiar $p_c(L)$, que é aleatório. Mostre que a média e o desvio padrão de $p_c(L)$ se aproximam de p_c e de zero como $L^{-1/\nu}$.

Solução. Seja $\Pi_L(p)$ a probabilidade de a amostra estar conectada (percolando) no nível p. Como abrir mais ligações só ajuda, "a amostra percola em p" é o mesmo que "o limiar da amostra é $\le p$". Então $\Pi_L(p) = \Pr[p_c(L) \le p]$ é a *distribuição acumulada* de $p_c(L)$, e sua derivada é a densidade. Por escala, $\Pi_L(p) = \Phi[(p - p_c)L^{1/\nu}]$. Mudando de variável para $z = (p - p_c)L^{1/\nu}$, que tem uma distribuição fixa (independente de L),

$$p_c(L) = p_c + z\, L^{-1/\nu} \quad\Longrightarrow\quad \big\langle p_c(L)\big\rangle - p_c = \langle z\rangle\, L^{-1/\nu}, \qquad \sigma[p_c(L)] = \sigma_z\, L^{-1/\nu}.$$

Os dois decaem com o mesmo expoente. A largura é mais útil para medir ν, porque não exige conhecer p_c. ◂

[2] Problema 1. Usando a hipótese de escala, mostre que o pico do segundo maior cluster escala como $S_2^{\max} \sim L^{d_f}$. *Dica:* em p_c, os dois maiores clusters são ambos "o maior cluster numa caixa de lado $\sim L$".

2 Por que $p_c(L)$ deriva

Na rede quadrada, o limiar médio das amostras finitas fica *acima* de $1/2$ e se aproxima por cima. A razão é geométrica: as bordas. Um nó na borda tem menos vizinhos, e a rede finita é "mais fraca" que a infinita, então precisa de mais ligações abertas para percolar. O efeito de borda decai como (fração de nós na borda) $\sim 1/L$, mas o que domina é a janela crítica, $\sim L^{-1/\nu} = L^{-3/4}$, que é *maior* que $1/L$.

[2] Problema 2. Em Fortaleza, a fração de cruzamentos na borda do recorte é bem maior que numa grade quadrada de mesmo N, porque o recorte corta muitas ruas. O que você espera para o p_c de Fortaleza comparado ao de uma grade infinita com a mesma estrutura local? E comparado ao de um recorte duas vezes maior da mesma cidade?

3 Um experimento numérico completo

Para $L = 16, 32, 64, 128$, sorteamos r uniforme em cada ligação da rede quadrada (600 amostras; 300 para $L = 128$) e medimos, em cada amostra, $p_c(L) = 1 - q_c$ e o pico de S_2:

L	$\langle p_c(L) \rangle$	largura $\sigma[p_c(L)]$	$\langle S_2^{\max} \rangle$	$\langle S_2^{\max} \rangle / N$
16	0,5131	0,0580 ± 0,0017	55,4 ± 0,8	0,216
32	0,5083	0,0340 ± 0,0010	203,7 ± 2,9	0,199
64	0,5060	0,0216 ± 0,0007	782 ± 12	0,191
128	0,5044	0,0125 ± 0,0005	2780 ± 56	0,170

Ideia 2

Ajustes em log-log. Se $y = AL^a$, então $\ln y = \ln A + a \ln L$, uma reta. Ajustando por mínimos quadrados os quatro pontos:

- largura: inclinação $-0{,}728$, ou seja, $1/\nu = 0{,}728$ (exato: 0,75);
- $S_2^{\max}$: inclinação 1,889, ou seja, $d_f = 1{,}889$ (exato: $91/48 = 1{,}896$);
- fixando $1/\nu = 3/4$ e ajustando $\langle p_c(L) \rangle = p_c + aL^{-3/4}$: $p_c = 0{,}502$ (exato: 0,5).

Com 20 segundos de computação, recuperamos os expoentes exatos da percolação 2D com erro de 1 a 3%.

[3] Problema 3. Expoentes efetivos. Calcule as inclinações "locais" entre pares consecutivos de L na tabela, para a largura e para $S_2^{\max}$. Elas se aproximam de um valor fixo? O que você conclui sobre a confiabilidade do ajuste com quatro pontos? Por que as inclinações locais oscilam?

[2] Problema 4. A última coluna mostra que $S_2^{\max}/N$ cai devagar. Qual expoente a teoria prevê para essa queda? Os dados concordam?

[3] Problema 5. Colapso de dados. Descreva, passo a passo, como você faria o colapso de S_1/N com os dados de $L = 16, \ldots, 128$, e o que faria se o colapso ficasse "quase bom" mas não perfeito. Que parâmetros você pode ajustar? Como saber se o ajuste é bom?

4 Barras de erro honestas

Ideia 3

- **Erro padrão da média:** com n amostras independentes de desvio s, a média tem incerteza $s/\sqrt{n}$.
- **Bootstrap:** para a incerteza de qualquer outra coisa (o desvio padrão, um expoente, uma razão), sorteie com reposição n amostras dentre as n originais, recalcule a grandeza e repita centenas de vezes. O desvio padrão dessas réplicas é a barra de erro. A incerteza da largura na tabela acima foi calculada assim, com 300 réplicas.
- **Teste pareado:** se duas estratégias foram avaliadas nas *mesmas* amostras, compare as diferenças amostra a amostra (P2, Problema 8).

Exemplo 2. Com n amostras gaussianas, a incerteza relativa do desvio padrão amostral é $\approx 1/\sqrt{2n}$. Quantas amostras são necessárias para medir a largura com 3% de precisão? Confira com a tabela.

Solução. $1/\sqrt{2n} = 0{,}03$ dá $n \approx 560$. Na tabela, com $n = 600$: $0{,}0017/0{,}0580 = 2{,}9\%$ para $L = 16$ e $0{,}0010/0{,}0340 = 2{,}9\%$ para $L = 32$. Com $n = 300$ ($L = 128$): $1/\sqrt{600} = 4{,}1\%$, contra $0{,}0005/0{,}0125 = 4\%$ medido. A distribuição de $p_c(L)$ é quase gaussiana. ◂

[3] Problema 6. Propague o erro: se as larguras em L_1 e $L_2 = 2L_1$ têm incerteza relativa ϵ cada uma, qual é a incerteza do expoente local $1/\nu = -\ln(w_2/w_1)/\ln 2$? Quantas amostras por tamanho seriam necessárias para medir cada expoente local com incerteza $\pm 0{,}02$?

5 E em Fortaleza?

Com r uniforme e independente em cada via, a malha de Fortaleza tem $\langle p_c \rangle = 0{,}564$ e largura $\sigma[p_c] = 0{,}034$ (400 amostras). A rede quadrada com $L \approx \sqrt{2470} \approx 50$ teria largura $\approx 0{,}058\,(50/16)^{-3/4} = 0{,}025$.

[2] Problema 7. Por que a largura de Fortaleza é maior que a da rede quadrada de mesmo N? Dê pelo menos duas razões. Proponha como medir o "L efetivo" de uma malha irregular.

Soluções

Problema 1. Em p_c, $\xi \gtrsim L$, e os clusters grandes são fractais limitados pela caixa: o maior tem massa $\sim L^{d_f}$. O segundo maior é "o maior que sobrou", ainda limitado só por L, e por escala tem a mesma forma $S_2 = L^{d_f}\mathcal{G}[(p - p_c)L^{1/\nu}]$, com $\mathcal{G}$ fixa. O máximo de $\mathcal{G}$ é um número, então $S_2^{\max} \sim L^{d_f}$.

Problema 2. Muitas bordas tornam a rede efetivamente mais fraca, e o p_c medido fica *acima* do da grade infinita equivalente. Um recorte duas vezes maior tem relativamente menos borda, e seu p_c deve ser menor, mais perto do valor "infinito". Em tamanho finito, $p_c(L) - p_c(\infty) \sim L^{-1/\nu}$. Parte do 0,564 de Fortaleza (comparado ao 0,5 da grade) é efeito de tamanho e de borda, e parte vem da estrutura (becos, grau médio 3,37).

Problema 3. Largura: 0,77, 0,65, 0,79. $S_2^{\max}$: 1,88, 1,94, 1,83. Elas oscilam em torno dos valores exatos, sem tendência clara. O ruído estatístico (cada largura tem ≈ 3–4% de erro, e um expoente local entre dois pontos tem erro $\approx \sqrt{2} \cdot 0{,}04/\ln 2 \approx 0{,}08$) é maior que qualquer correção sistemática visível. O ajuste global com quatro pontos é razoável, mas as barras de erro dos expoentes são $\sim \pm 0{,}03$, e não seria honesto citar três casas decimais.

Problema 4. $S_2^{\max}/N \sim L^{d_f - 2} = L^{-5/48} = L^{-0{,}104}$. De $L = 16$ a 128 (fator 8), a previsão é uma queda por $8^{-0{,}104} = 0{,}81$. Os dados dão $0{,}170/0{,}216 = 0{,}79$. Concordam.

Problema 5. (1) Escolha p_c, ν e β/ν (comece pelos valores teóricos). (2) Para cada L, faça o gráfico de $y = (S_1/N)L^{\beta/\nu}$ contra $x = (p - p_c)L^{1/\nu}$. (3) Se as curvas não coincidem, ajuste os três parâmetros para minimizar a dispersão entre as curvas numa janela em torno de $x = 0$ (por exemplo, a soma dos quadrados das distâncias entre curvas interpoladas). (4) Para saber se é bom: a dispersão residual deve ser compatível com as barras de erro, e os parâmetros não podem mudar muito ao estreitar a janela ou ao retirar o menor L. Se mudam, há correções de escala, e só os tamanhos maiores devem entrar.

Problema 6. $\delta(1/\nu) = \frac{1}{\ln 2}\sqrt{\epsilon^2 + \epsilon^2} = \frac{\sqrt{2}\,\epsilon}{\ln 2} \approx 2{,}04\,\epsilon$. Para $\pm 0{,}02$, precisamos de $\epsilon \approx 0{,}0098$, e com $\epsilon \approx 1/\sqrt{2n}$ isso dá $n \approx 5200$ amostras por tamanho. Medir expoentes com precisão é caro, e por isso se usam muitos tamanhos e ajustes globais, em vez de pares.

Problema 7. (i) A malha é irregular: tem becos e regiões de grau baixo, e quarteirões de tamanhos variados. A desordem estrutural soma flutuações entre amostras. (ii) O recorte é retangular e alongado (cerca de 6,4 km por 3,8 km), e o lado menor controla a conexão, então o L efetivo é menor que $\sqrt{N}$. (iii) Há muita borda. Para medir o L efetivo: meça a largura em recortes de vários tamanhos da mesma cidade e ajuste $\sigma = A\,L_{\text{ef}}^{-3/4}$; ou defina L_{ef} pelo número médio de passos do caminho mínimo entre lados opostos (a "distância química").